PFE — Chatbot Intelligent pour Marketplace ASMAD

Université / Encadrant / Étudiant : à compléter

- **Problème :** aider l'utilisateur à trouver rapidement le bon produit
- **Solution :** chatbot hybride (règles métier + RAG + génération IA)
- **Impact :** meilleure conversion, meilleure expérience client

1) Contexte et Problématique

- Une marketplace contient beaucoup de produits : la recherche classique n'est pas toujours suffisante.
- L'utilisateur exprime souvent son besoin en langage naturel : "je veux un article pour...".
- Objectif : transformer une demande textuelle en recommandations concrètes.
- Contrainte : ne proposer que des produits disponibles et réellement existants en base.

Message clé : le chatbot est un assistant d'achat, pas un simple gadget.

2) Objectifs du Chatbot

- Comprendre la demande utilisateur en français.
- Récupérer des produits pertinents (titre, description, catégorie).
- Répondre avec texte + recommandations structurées (id, nom, prix, image).
- Garder un mode dégradé sans clé OpenAI.
- Intégrer des réponses prédictives selon le rôle (admin / vendeur).

3) Stack Technique

- **Frontend :** Vue 3, Vue Router, Axios
- **UI :** widget de chat intégré dans l'application
- **Auth :** JWT côté client

- **Backend :** NestJS 11, TypeORM, MySQL
- **IA :** OpenAI (chat + embeddings)
- **Sécurité :** JwtAuthGuard, contrôle des rôles

Important : gestion des images via API interne (upload + base), pas Cloudinary.

4) Architecture du Chatbot

- Endpoint principal : `POST /chat` (protégé par JWT).
- Endpoint d'indexation : `POST /chat/reindex` (admin uniquement).
- Service central : `ChatService` .
- Service vectoriel : `EmbeddingService` .
- Réponse type : `{ reply, recommended[] }` .

5) Pipeline de Traitement

- 1. Validation du message utilisateur (`ChatRequestDto`).
- 2. Détection d'intention spéciale (prévision pour admin/vendeur).
- 3. Chargement du catalogue disponible (**status DISPONIBLE + stock > 0**).
- 4. Filtrage mots-clés + ranking sémantique (cosine similarity).
- 5. Génération de réponse contrôlée (prompt système anti-hallucination).

6) Stratégie RAG Implémentée

- Le système n'envoie pas tout le catalogue : il envoie un **contexte top-K**.
- Contexte = intersection "match lexical" + "similarité vectorielle".
- Embeddings stockés en base (`embeddingJson`) et réindexables.
- Le modèle reçoit des règles strictes : ne recommander que les produits du contexte.
- Résultat : réponse plus précise, moins d'hallucinations.

7) Mode Dégradé (Sans OpenAI)

- Si `OPENAI_API_KEY` est absente, le chatbot reste fonctionnel.
- Mode fallback : filtrage par mots-clés uniquement, sans génération LLM.
- Réponse explicite pour guider l'utilisateur vers de meilleurs mots-clés.
- Avantage : robustesse de service même en cas de panne externe.

8) Fonctionnalité Avancée : Prévisions

- Le chatbot détecte des intentions de type "prévision" dans le message.
- **Admin :** projection du CA/profit plateforme sur 5 mois.
- **Vendeur :** projection des unités vendues sur 5 mois.
- Méthode actuelle : régression linéaire sur historique mensuel.
- Valeur : assistant décisionnel, pas seulement assistant commercial.

9) Sécurité et Gouvernance

- Accès au chat protégé par JWT (`JwtAuthGuard`).
- Réindexation réservée aux administrateurs.
- Validation DTO pour limiter les payloads invalides.
- Gestion d'erreurs OpenAI : indisponibilité proprement remontée.
- Recommandation PFE : rate limiting + logs structurés + monitoring.

10) Démonstration (Script oral 2-3 min)

- Cas 1 : "Je cherche un téléphone à petit budget" → produits proposés.
- Cas 2 : "Prévision de ventes sur 5 mois" avec compte vendeur.
- Cas 3 : arrêt de la clé OpenAI → bascule automatique en mode fallback.
- Cas 4 : reindex admin après import de nouveaux produits.

Astuce soutenance : montrer au jury une réponse correcte + une réponse refusée (produit absent), pour prouver le contrôle des hallucinations.

11) Résultats et Bénéfices

+UX

- Recherche plus naturelle
- Moins de friction dans le parcours
- Réponses contextualisées

+Métier

- Mise en avant des produits pertinents
- Vision prévisionnelle simple
- Architecture extensible

12) Limites Actuelles

- Évaluation qualité à formaliser avec un jeu de tests conversationnels.
- Métriques chatbot (taux de clic, conversion assistée) à instrumenter davantage.
- Régression linéaire utile mais limitée face aux saisonnalités complexes.
- Stockage image en base à revisiter pour très grande échelle.

13) Feuille de Route

- Passer à un vrai pipeline d'évaluation (précision recommandation, satisfaction).
- Ajout de mémoire conversationnelle contrôlée et profils d'intention.
- A/B testing entre différentes stratégies de récupération.
- Observabilité complète (traces, coûts token, latence P95).
- Durcissement production : cache, files d'attente, quotas et alerting.

Merci pour votre attention

Questions / Démonstration live

- **Message final :** chatbot utile, maîtrisé techniquement, aligné avec les besoins métier.